APRESENTAÇÃO DE ARTIGO 1 · INTRODUÇÃO AO APRENDIZADO DE MÁQUINA PARA SAÚDE · UFF

Injury Prediction in Competitive Runners With Machine Learning

Predição de lesões em corredores competitivos com aprendizado de máquina

S. Sofie Lövdal, Ruud J. R. den Hartigh e George Azzopardi

Int. Journal of Sports Physiology and Performance, 2021 · 16(10): 1522–1531 · doi.org/10.1123/ijspp.2020-0518

Apresentação: Gabriel Abreu Alves da Silva e Silva

MOTIVAÇÃO E PROBLEMA

Prever lesões é difícil, mas há muitos dados de carga

Relevância

Ficar livre de lesões é decisivo para a preparação e o desempenho do atleta.

Desafio

Estresse físico, recuperação e resposta individual interagem de forma não linear.

Oportunidade

Relógios GPS e registros de percepção geram históricos detalhados de carga.

Lacuna: os dados de carga de treino têm sinal suficiente para prever lesões em corredores competitivos?

OBJETIVO

“Com que precisão modelos de ML preveem uma lesão em corredores a partir da carga de treino anterior?”

Abordagem diária

7 dias anteriores, 10 atributos por dia: 70 no total.

Abordagem semanal

3 semanas anteriores, 22 atributos por semana mais 3 de variação: 69 no total.

Objetivo claro: lesão = sessão não completada; saudável = 3 semanas sem lesão antes e depois.

METODOLOGIA: DADOS

74 corredores acompanhados por 7 anos

74
corredores de média e longa distância

2012–19
período de coleta

583
eventos de lesão

Variáveis objetivas

Nº de sessões, km total, km por zona de intensidade, km de sprint, força e treino alternativo.

Variáveis subjetivas

Esforço, sucesso do treino e recuperação percebidos.

Todas as variáveis são normalizadas por atleta (z-score).

METODOLOGIA: MODELO E VALIDAÇÃO

XGBoost com bagging balanceado

1

Amostras balanceadas

2.048 lesões e 2.048 dias saudáveis por modelo

2

9 modelos XGBoost

Árvores rasas (profundidade 2–3), taxa de 0,01, sem ajuste fino

3

Média calibrada

Média dos 9 modelos, calibrada com Platt

Validação: treino com os 64 atletas mais antigos e teste com os 10 mais recentes, média de 5 repetições.
Métricas: AUC, sensibilidade e especificidade, com limiar escolhido na validação.

PRINCIPAIS RESULTADOS

A abordagem diária discrimina melhor que a semanal

0,724

AUC da abordagem diária (7 dias)

0,678

AUC da abordagem semanal (3 semanas)

58%

de sensibilidade (abordagem diária)

74%

de especificidade (abordagem diária)

CONTRIBUIÇÃO

O que o artigo acrescenta à literatura

Dados abertos

Base pública (CC0) com 7 anos de treino real de corredores.

Escala temporal

Compara as abordagens diária e semanal.

Dados combinados

Une dados objetivos do GPS a percepções subjetivas.

Referência

A base já foi reutilizada por estudos posteriores.

LIMITAÇÕES E ANÁLISE CRÍTICA

Há sinal preditivo, mas ele é moderado

Reconhecidas pelos autores

Lesões agudas são difíceis de prever; há poucos eventos; calçado e biomecânica ficaram de fora.

Identificada por mim

O teste usa só 10 atletas. Num teste preliminar, só o ID do atleta já chega a AUROC de 0,656.

Os resultados sustentam as conclusões?

Em parte: há sinal, mas com muitos falsos alarmes e sem validação em outras equipes.

OPORTUNIDADES DE PESQUISA

O que dá para fazer a partir daqui

1

Validação mais robusta

Validação cruzada agrupada por atleta com os 74 atletas.

2

Comparação de modelos

Regressão logística, Random Forest e XGBoost, com AUPRC.

3

Outros esportes e variáveis

Futebol (Rossi et al., 2018), calçado e biomecânica.

Lövdal, den Hartigh e Azzopardi (2021). IJSPP, 16(10), 1522–1531. doi.org/10.1123/ijspp.2020-0518