APRESENTAÇÃO DE ARTIGO 2 · INTRODUÇÃO AO APRENDIZADO DE MÁQUINA PARA SAÚDE · UFF

Effective injury forecasting in soccer with GPS training data and machine learning

Previsão de lesões no futebol com dados de GPS de treino e aprendizado de máquina

A. Rossi, L. Pappalardo, P. Cintia, F. M. Iaia, J. Fernàndez e D. Medina

PLoS ONE, 2018 · 13(7): e0201264 · doi.org/10.1371/journal.pone.0201264

Apresentação: Gabriel Abreu Alves da Silva e Silva

MOTIVAÇÃO E PROBLEMA

Indicadores isolados preveem mal as lesões

Custo das lesões

Lesões prejudicam o time e geram altos custos de reabilitação.

Limite atual

Índices como o ACWR (carga aguda/crônica) olham uma variável por vez.

Oportunidade

O GPS registra a carga de cada jogador em cada sessão.

Lacuna: faltava avaliar modelos multivariados, que combinam várias medidas de carga, para prever lesões.

OBJETIVO

“Dá para prever se um jogador vai se lesionar na próxima sessão a partir da carga recente medida por GPS?”

Prever a lesão

Classificar cada sessão como pré-lesão ou não, com um modelo interpretável.

Simular o uso real

Retreinar o modelo toda semana e prever a semana seguinte.

Objetivo claro: alvo, horizonte (próxima sessão) e interpretabilidade bem definidos.

METODOLOGIA: DADOS

Uma temporada de um clube italiano

26
jogadores profissionais

931
sessões com GPS

23
lesões sem contato

23
semanas (2013/14)

GPS (12)

Distância total, em alta velocidade, acelerações, desacelerações e outras.

Pessoais (6)

Idade, IMC, posição, lesões anteriores, minutos e jogos.

Derivados (55 no total)

Médias móveis (EWMA), ACWR e monotonia da carga (MSWR).

METODOLOGIA: MODELO E VALIDAÇÃO

Árvore de decisão interpretável

1

Seleção de atributos

Eliminação recursiva com validação cruzada (RFECV)

2

Oversampling

ADASYN cria lesões sintéticas, só no treino

3

Árvore de decisão

Gera regras que a comissão técnica entende

Validação: validação cruzada estratificada em 2 folds (10.000 repetições) e cenário evolutivo semanal.
Comparações: Random Forest, regressão logística, previsores ACWR e MSWR.
Métricas: precisão, recall e F1 da classe lesão, e AUC.

PRINCIPAIS RESULTADOS

A árvore detecta 80% das lesões

0,80

de recall: lesões detectadas

0,50

de precisão: alertas corretos

0,76

de AUC (± 0,12)

Cenário evolutivo: retreinando a cada semana, o modelo previu 9 das 14 lesões da semana 6 ao fim da temporada (F1 = 0,60).

CONTRIBUIÇÃO

O que o artigo acrescenta à literatura

Multivariado

Combina várias métricas de GPS e supera indicadores isolados como o ACWR.

Interpretável

A árvore final usa só 3 atributos: lesões anteriores, corrida em alta velocidade e monotonia.

Cenário realista

Simula o uso semanal no clube, treinando só com dados do passado.

Custo

Estima redução de 77% no custo com lesões ao longo da temporada.

LIMITAÇÕES E ANÁLISE CRÍTICA

Resultados promissores, mas com amostra pequena

Reconhecidas pelos autores

Um clube, uma temporada e 26 jogadores; só treinos; o oversampling cria exemplos sintéticos.

Identificada por mim

Validação em só 2 folds e oversampling com pouquíssimas lesões tendem a gerar resultados otimistas.

Os resultados sustentam as conclusões?

Em parte: o cenário evolutivo convence, mas 14 lesões no teste são pouco para generalizar.

COMPARAÇÃO COM O ARTIGO 1

Lövdal (2021) × Rossi (2018)

	Artigo 1 — Lövdal et al. (2021)	Artigo 2 — Rossi et al. (2018)
Problema	Lesão em corredores pela carga dos 7 dias ou 3 semanas anteriores	Lesão na próxima sessão de futebol pela carga de GPS
Dados	74 corredores, ~7 anos, 583 lesões; público	26 jogadores, 1 temporada, 23 lesões
Modelo	9 XGBoost com bagging balanceado e calibração	Árvore de decisão com RFECV e ADASYN
Avaliação	Teste com 10 atletas novos; AUC, sensibilidade, especificidade	CV em 2 folds e cenário semanal; precisão, recall, F1, AUC
Resultados	AUC 0,724 (diária) e 0,678 (semanal)	Recall 0,80, precisão 0,50, AUC 0,76
Limitações	Sinal moderado; muitos falsos alarmes	Amostra muito pequena; um clube

OPORTUNIDADES DE PESQUISA

O que dá para fazer a partir daqui

1

Validação externa

Outros clubes, temporadas e o futebol feminino.

2

Mais dados

Carga das partidas, dados de saúde e modelos por jogador.

3

Conexão com o projeto

Validação temporal (passado → futuro) nos corredores.

Rossi et al. (2018). PLoS ONE, 13(7), e0201264. doi.org/10.1371/journal.pone.0201264