INTRODUÇÃO AO APRENDIZADO DE MÁQUINA PARA SAÚDE · UFF · PROJETO DE APLICAÇÃO

Predição de lesões em corredores competitivos

Resultados: 6 modelos, 2 abordagens e validação separada por atleta

Gabriel Abreu Alves da Silva e Silva

MOTIVAÇÃO

Prever o risco de lesão a partir do log de treino

Lesões por sobrecarga surgem do desequilíbrio entre carga e recuperação. Os treinadores registram a carga todos os dias, mas a interpretam de forma subjetiva.

Pergunta de pesquisa

Com a carga e as percepções recentes, dá para estimar o risco de lesão de um corredor que o modelo nunca viu?

Uso pretendido

Triagem: sinalizar dias de risco elevado para revisar a carga de treino. Não é um instrumento diagnóstico.

DADOS

74 corredores de alto nível, 7 anos de treino registrado

74
atletas: 27 mulheres e 47 homens

2012–19
período dos registros

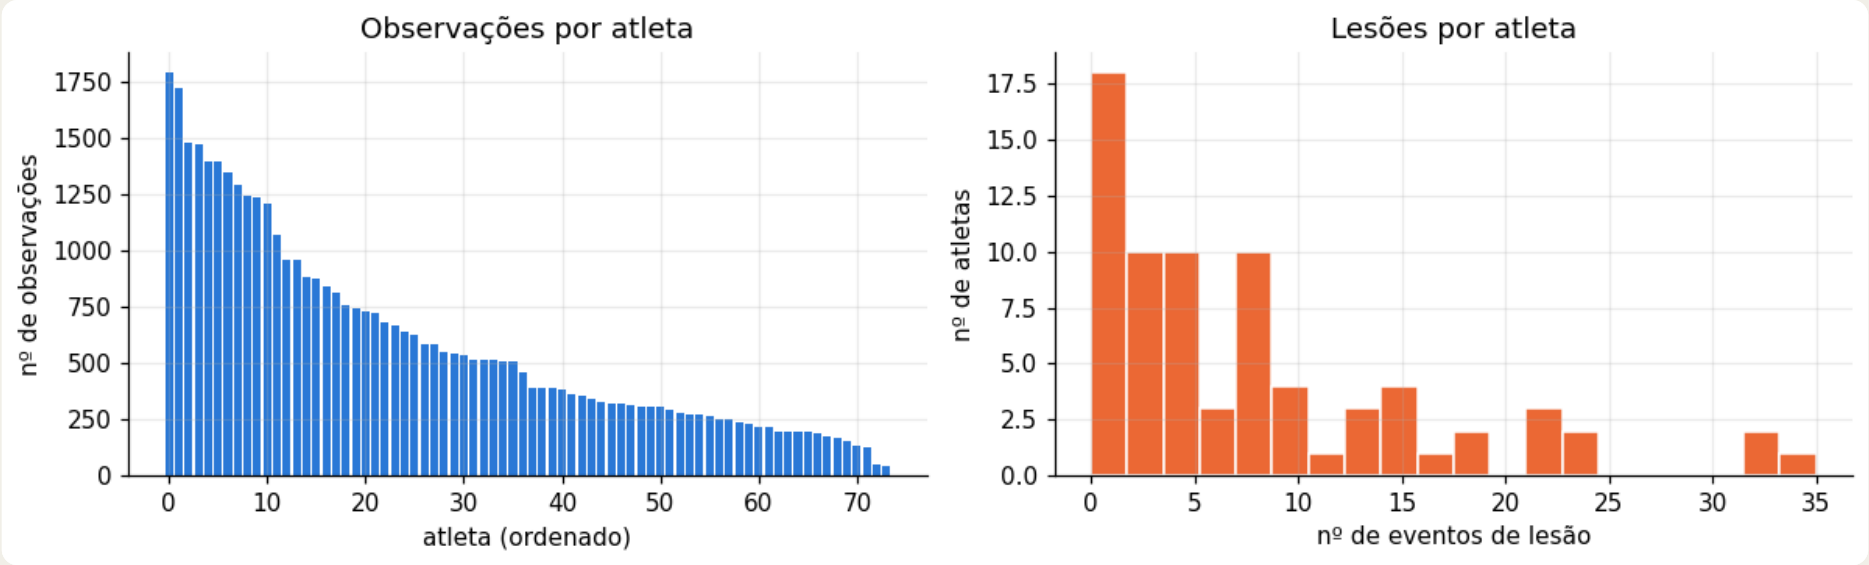
42,8 mil
dias-atleta por abordagem

1,35%
dos dias com lesão

Abordagem	Histórico usado	Variáveis de entrada	Lesões
Por dia	7 dias anteriores	10 × 7 dias = 70	583
Por semana	3 semanas anteriores	22 × 3 semanas = 66	575

DADOS POR ATLETA

Poucos atletas concentram boa parte dos dados



Mediana de 427 dias e 5 lesões por atleta; um atleta tem 1.791 dias e outro chega a 35 lesões. Por isso a divisão entre treino, validação e teste é feita por atleta.

MÉTODO

Cada atleta fica em um único conjunto

1

Normalização por atleta

Cada variável vira o desvio em relação ao histórico do próprio corredor

2

Divisão por atleta

48 atletas no treino, 12 na validação e 14 no teste

3

Ajuste na validação

Early stopping e limiar de decisão escolhidos sem tocar no teste

4

Avaliação

Teste usado uma vez, mais validação cruzada em 5 folds por atleta

Sem atleta repetido entre conjuntos, o modelo é avaliado como seria diante de um corredor novo.

MODELOS

Seis modelos, da referência mínima ao ensemble

Modelo	Como funciona	Desbalanceamento
Classe majoritária	Prevê sempre “sem lesão”; referência mínima	—
Regressão logística	Soma ponderada das variáveis, regularização L2	Pesos de classe
Random Forest	Média de 300 árvores de decisão	Pesos de classe
XGBoost	Árvores rasas em sequência, com early stopping	Peso maior para lesão
Bagged XGBoost	Média de 25 XGBoost, cada um com amostra 1:1	Subamostragem
MLP	Rede neural, 32 neurônios, dropout de 0,5	Peso maior para lesão

AVALIAÇÃO

AUROC como métrica principal, sempre por atleta

AUROC

Chance de um dia com lesão receber escore maior que um dia sem lesão. 0,5 equivale ao acaso.

Lift da AUPRC

AUPRC dividida pela prevalência: quantas vezes melhor que o acaso para encontrar as lesões.

Limiar comum

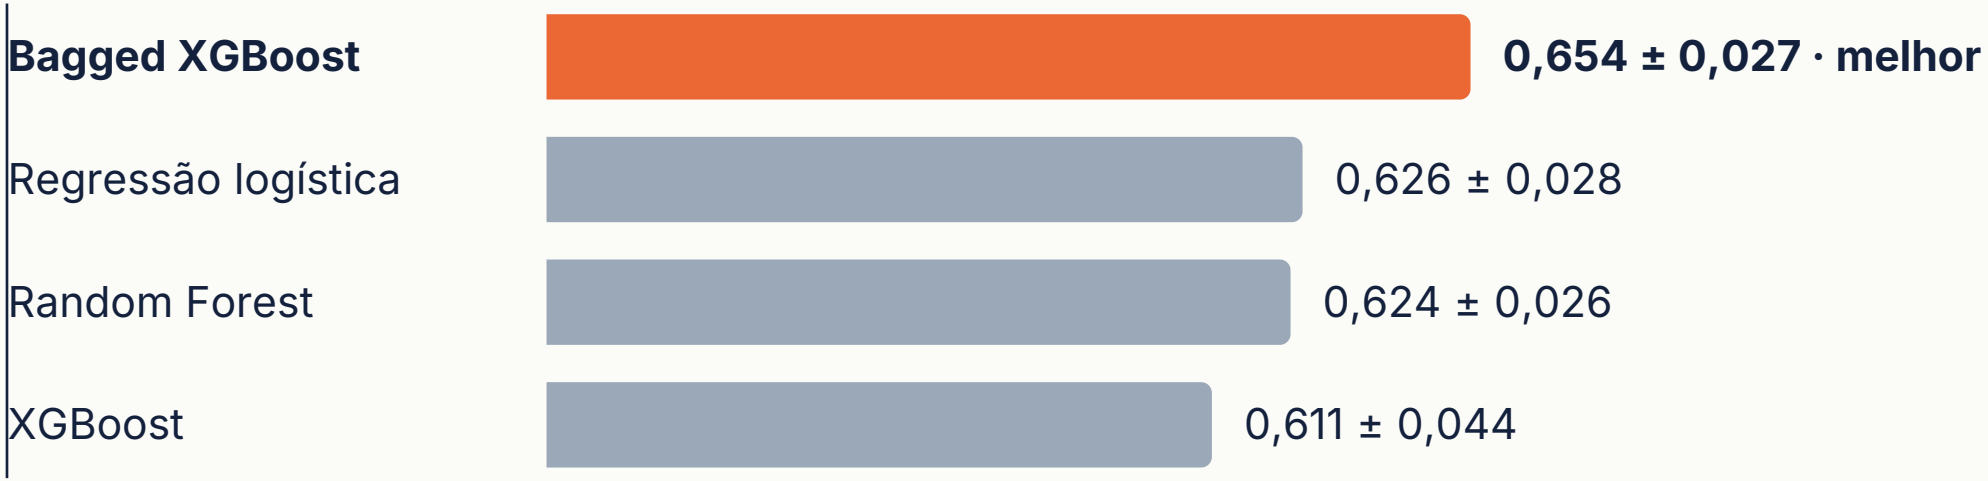
Escolhido na validação para 80% de especificidade, igual para todos os modelos.

Estimativa principal: média da validação cruzada em 5 folds. No teste, IC de 95% por bootstrap reamostrando atletas.

RESULTADO PRINCIPAL

Bagged XGBoost lidera na abordagem por dia

AUROC média na validação cruzada (5 folds por atleta), abordagem por dia com normalização por atleta



Eixo começa em 0,50 (acaso). Barra = média; ± = desvio-padrão entre folds.

DIA × SEMANA

O histórico diário carrega mais sinal que o semanal

Modelo (AUROC na CV)	Dia, com norm.	Dia, sem norm.	Semana, com norm.	Semana, sem norm.
Bagged XGBoost	0,654	0,637	0,625	0,626
Regressão logística	0,626	0,614	0,609	0,617
Random Forest	0,624	0,592	0,625	0,629
XGBoost	0,611	0,594	0,606	0,618

Por semana, todos os modelos ficam entre 0,606 e 0,629, com desvios entre folds maiores que as diferenças entre eles. Em negrito, o melhor de cada coluna.

CONJUNTO DE TESTE

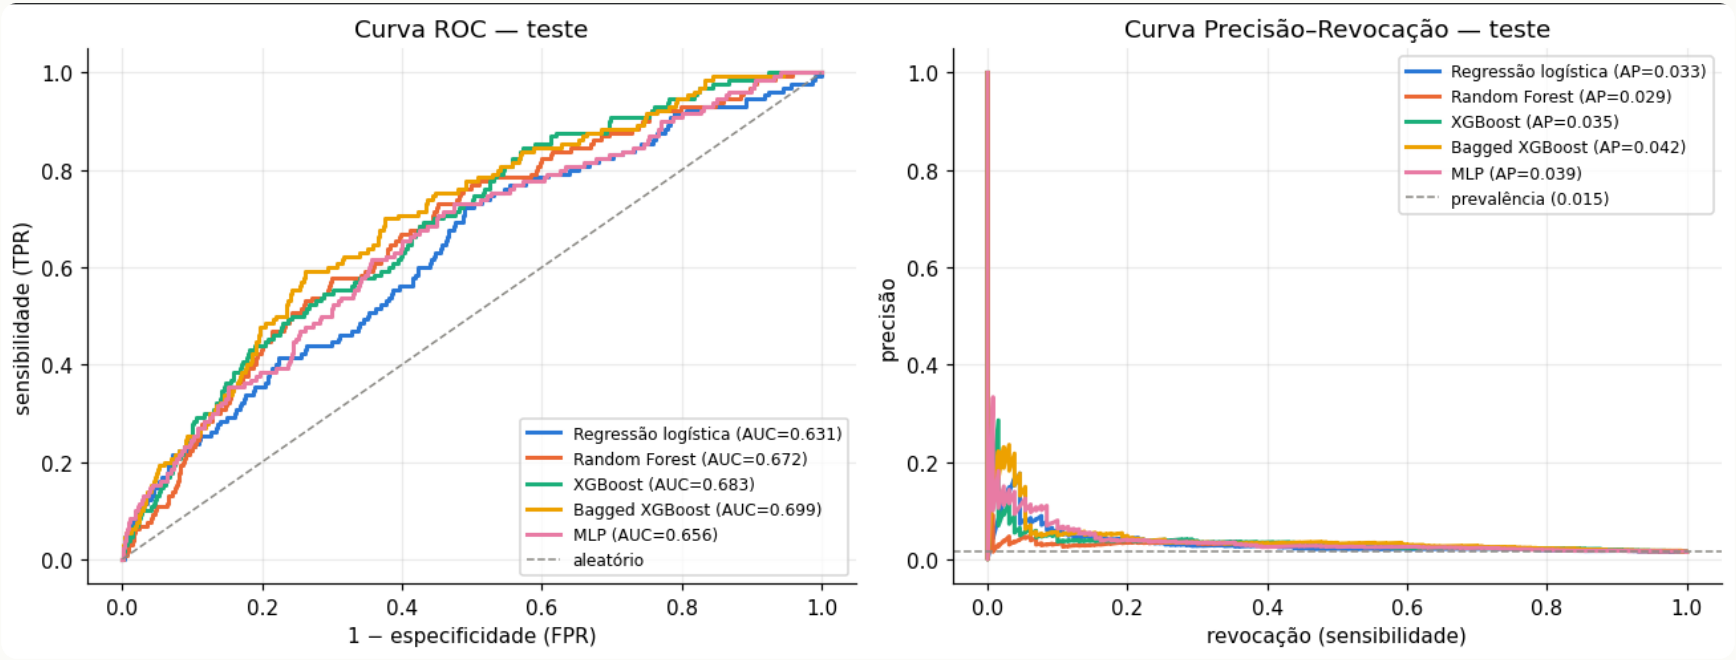
No teste, o Bagged XGBoost chega a 0,699 de AUROC

Modelo	AUROC [IC 95%]	Lift	Sens.	Espec.	VPP
Classe majoritária	0,500	1,00	0%	100%	—
Regressão logística	0,631 [0,585; 0,685]	2,17	35%	80%	2,7%
Random Forest	0,672 [0,592; 0,738]	1,88	28%	89%	3,6%
XGBoost	0,683 [0,598; 0,753]	2,34	29%	90%	4,1%
Bagged XGBoost	0,699 [0,637; 0,760]	2,74	32%	86%	3,4%
MLP	0,656 [0,598; 0,718]	2,56	39%	78%	2,7%

Abordagem por dia com normalização: 14 atletas e 130 lesões. O teste coincide com o fold mais favorável da validação cruzada, por isso fica acima da média de 0,654.

CONJUNTO DE TESTE

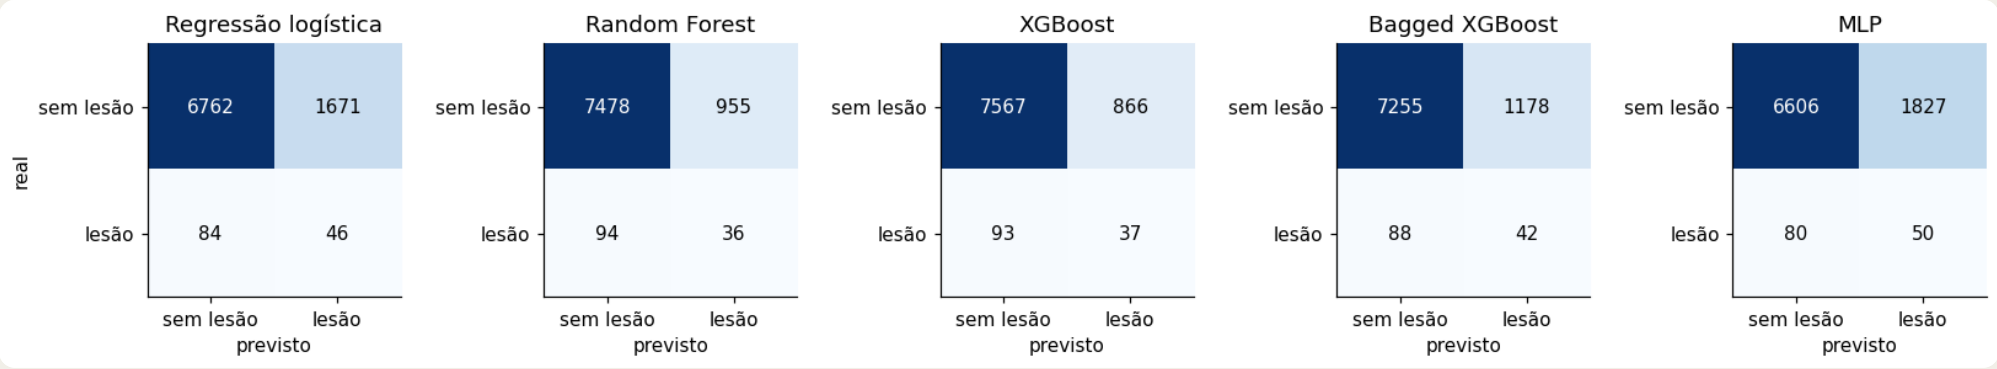
Curvas ROC e de precisão–revocação no teste



Todas as curvas ROC ficam acima do acaso. Na curva PR, a precisão só sobe (até 0,2–0,3) nos dias de maior escore; no resto, fica perto da prevalência de 0,015.

CONJUNTO DE TESTE

Matrizes de confusão: muitos alarmes para cada lesão detectada



42 de 130

lesões detectadas pelo Bagged XGBoost

1.178

falsos alarmes em 8.433 dias sem lesão

37 a 50

lesões detectadas pelos demais modelos

ESTABILIDADE

O bagging estabiliza o XGBoost

1 a 642

árvores escolhidas pelo early stopping do XGBoost isolado, conforme o fold

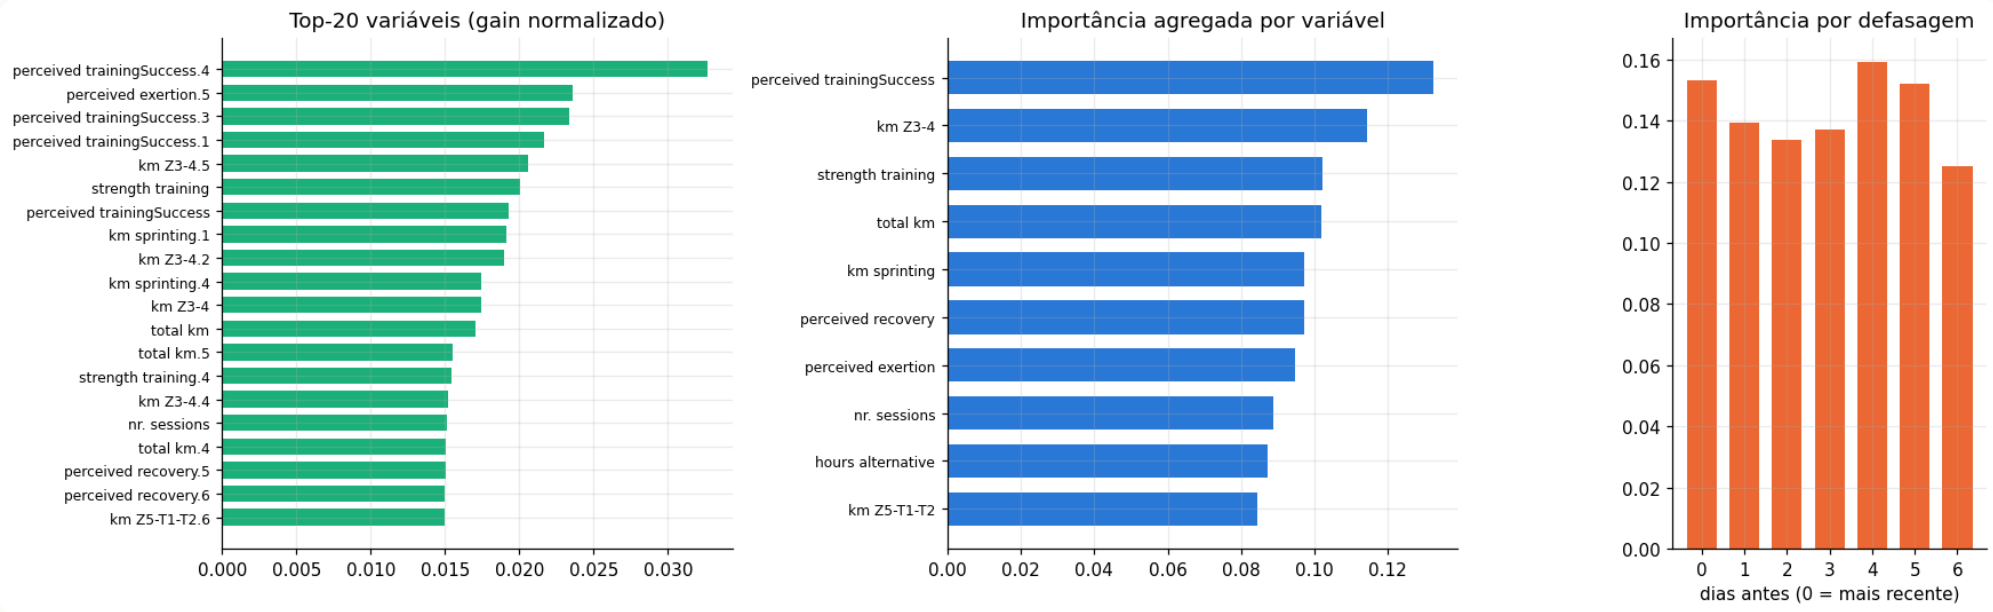
4 de 4

configurações em que o Bagged XGBoost supera o XGBoost isolado

Com 70 a 130 lesões na validação interna, o ponto de parada vira sorteio. O Bagged XGBoost faz a média de 25 modelos com número fixo de árvores, como em Lövdal et al. (2021).

INTERPRETAÇÃO

A percepção de sucesso do treino é a variável mais usada



Ganho no XGBoost (por dia): o peso se espalha pelos 7 dias anteriores.

NORMALIZAÇÃO POR ATLETA

Comparar cada atleta com ele mesmo ajuda

Por dia

+0,01 a 0,03

de AUROC em todos os modelos

Por semana

1,56 → 2,04

de lift da AUPRC no Bagged XGBoost; a AUROC quase não muda

Ressalva: a normalização usa estatísticas de todo o período do atleta, então parte do ganho pode ser otimista.

NA PRÁTICA

Cerca de 1 lesão real a cada 29 alertas

32%
das lesões detectadas

86%
de especificidade

3,4%
dos alertas viram lesão

Serve como sinal de risco para revisar a carga de treino, não como preditor de lesões individuais.

COMPARAÇÃO COM A LITERATURA

Abaixo do artigo de referência, com a mesma ordem

Abordagem	Lövdal et al. (2021)	Este trabalho (CV)
Por dia	0,724	0,654
Por semana	0,678	0,625

AUROC do Bagged XGBoost com normalização por atleta. Nos dois trabalhos, a abordagem diária supera a semanal.

Os dois separam treino e teste por atleta. A diferença provável está no protocolo: o artigo testa em 10 atletas, com média de 5 repetições; aqui, a validação cruzada cobre os 74.

LIMITES E PRÓXIMOS PASSOS

O que limita o resultado e o que testar depois

Limitações

- Cerca de 580 lesões e uma única equipe
- Normalização usa o período inteiro do atleta
- Saídas não são probabilidades calibradas
- Limiar de 80% não reflete o custo clínico
- Faltam histórico de lesões, sono e biomecânica

Trabalhos futuros

- Normalização só com dados passados
- Avaliação temporal: passado → futuro
- Calibração das probabilidades
- Combinar as abordagens dia e semana
- Validar em outros esportes (SoccerMon)

CONCLUSÕES

O que o projeto mostrou

1. A abordagem por dia supera a semanal: 0,654 contra no máximo 0,629 de AUROC.
2. O Bagged XGBoost é o modelo mais consistente e o mais estável.
3. A normalização por atleta melhora o ranqueamento das lesões.
4. O modelo serve para triagem de risco, não para diagnóstico.

Código, notebook e README: https://github.com/gabriel-abreu-ss/AMS-Projeto-Final