INTRODUÇÃO AO APRENDIZADO DE MÁQUINA PARA SAÚDE · UFF

Predição de lesões em corredores com Machine Learning

Apresentação do tema do projeto de aplicação

Gabriel Abreu Alves da Silva e Silva

MOTIVAÇÃO

Lesões são frequentes e ligadas à carga de treino

19–79%

dos corredores se lesionam por ano (van Gent et al., 2007)

Carga de treino

Volume e intensidade do treino estão associados ao risco de lesão (Gabbett, 2016).

Padrões não lineares

Modelos de ML podem captar relações complexas no histórico de cada atleta.

Quem se beneficia: atletas, treinadores e preparadores físicos, com um alerta para ajustar a carga antes da lesão.

PERGUNTA DE PESQUISA

“É possível prever lesões em corredores a partir da carga dos 7 dias anteriores, em atletas que o modelo nunca viu?”

Uso pretendido

Alerta de risco para a comissão técnica ajustar a carga de treino.

Escopo

Apoio à decisão; não substitui a avaliação médica.

FORMULAÇÃO DO PROBLEMA DE ML

Classificação binária de cada dia de treino

Entrada (X)

Carga e percepções dos 7 dias anteriores: 70 atributos

Modelo

Classificador treinado com outros atletas

Saída (y)

Lesão (1) ou não (0), com um escore de risco

Unidade de análise

Atleta-dia: cada linha é um dia de treino de um atleta.

Definição do alvo

y = 1: o atleta não completou a sessão por lesão. y = 0: saudável nas 3 semanas antes e depois.

DADOS

Dataset público de Lövdal et al. (2021)

74
corredores (27 mulheres, 47 homens)

2012–19
período de coleta

42.766
dias-atleta, 70 atributos

583
lesões: 1,36% dos dias, em 63 atletas

Volume

Nº de sessões, km total e km de sprint.

Intensidade

Km em Z3-4 e Z5-T1-T2, força e treino alternativo.

Percepção (0 a 1)

Esforço, sucesso do treino e recuperação.

DataverseNL, acesso aberto (CC0), DOI 10.34894/UWU9PV. Traz o ID do atleta e a data, então permite validar por atleta.

VIABILIDADE E RISCOS

Quatro riscos metodológicos e como mitigá-los

Risco	Por que preocupa	Mitigação
Desbalanceamento	Só 1,36% dos dias têm lesão	Pesos de classe ou subamostragem; métricas para classe rara
Concentração por atleta	5 atletas somam 25% das lesões	Divisão de treino e teste por atleta
Qualidade dos rótulos	Lesão autorrelatada; ~27% das percepções vazias (−0,01)	Normalização por atleta e cautela na interpretação
Atalhos e vazamento	O modelo pode reconhecer o atleta em vez da carga	Nenhum atleta em mais de um conjunto

ESTRATÉGIA INICIAL DE AVALIAÇÃO

Como saberemos se o modelo funciona

Baselines

Classe majoritária e regressão logística.

Modelos

Random Forest, XGBoost e XGBoost com bagging (Lövdal et al.).

Métricas

AUROC como principal; AUPRC, sensibilidade e especificidade.

Separação dos dados

Validação cruzada agrupada por atleta, em 5 folds.

Teste preliminar: regressão logística sem ajuste, separada por atleta, com AUROC de 0,634.

REFERÊNCIAS

Trabalhos relacionados

- Lövdal, den Hartigh e Azzopardi (2021). Injury Prediction in Competitive Runners With Machine Learning. IJSPP, 16(10). **Artigo 1**
- Rossi et al. (2018). Effective injury forecasting in soccer with GPS training data and machine learning. PLoS ONE, 13(7). **Artigo 2**
- van Gent et al. (2007). Incidence and determinants of lower extremity running injuries in long distance runners. Br J Sports Med, 41(8).
- Gabbett (2016). The training–injury prevention paradox. Br J Sports Med, 50(5).
- Van Eetvelde et al. (2021). Machine learning methods in sport injury prediction and prevention. J Exp Orthop, 8.
- Dataset: Replication Data for: Injury Prediction in Competitive Runners With Machine Learning. DataverseNL, doi.org/10.34894/UWU9PV.